

# Descenso de Gradiente en Ciencias Biomédicas

## Regresión lineal múltiple y regresión logística

PhD. Pablo Eduardo Caicedo Rodríguez

2026-09-27



# Objetivos de la sesión

- Entender el **principio del descenso de gradiente (GD)** como método de optimización.
- Aplicar GD a **regresión lineal múltiple** (objetivo continuo) y **regresión logística** (clasificación 0/1).
- Analizar decisiones de ingeniería: **tasa de aprendizaje, escalado/normalización, batch vs. mini-batch vs. SGD.**
- Interpretar resultados en **contextos biomédicos** (diagnóstico, pronóstico y evaluación de riesgo).

# Agenda

- 1 Fundamentos de GD y funciones de costo
- 2 Caso 1: **Regresión lineal múltiple** con GD
- 3 Caso 2: **Regresión logística** con GD
- 4 Buenas prácticas, diagnósticos y discusión aplicada




## Sección 1

### 1. Fundamentos de descenso de gradiente

# Motivación biomédica


- Ajustar parámetros de un **modelo fisiológico** o un **predictor clínico** con datos reales.
- Ejemplos típicos:
  - Estimar **gasto energético** a partir de IMC, edad y FC.
  - Estimar **edad vascular** con variables de laboratorio.
  - **Clasificar** presencia/ausencia de una condición (0/1) con biomarcadores.

# Regresión Lineal





# Regresión Lineal



# Función de costo (error)

**Regresión (continuo):**

$$J(\mathbf{w}) = \frac{1}{2m} \sum_{i=1}^m (y_i - \hat{y}_i)^2$$

donde  $\hat{y}_i = \mathbf{w}^\top \mathbf{x}_i$ .

**Clasificación binaria: Entropía cruzada (log-loss):**

$$J(\mathbf{w}) = -\frac{1}{m} \sum_{i=1}^m [y_i \log \hat{p}_i + (1 - y_i) \log (1 - \hat{p}_i)]$$

donde  $\hat{p}_i = \sigma(\mathbf{w}^\top \mathbf{x}_i) = \frac{1}{1 + e^{-\mathbf{w}^\top \mathbf{x}_i}}$ .

# Función de costo (error)

! ... Para el caso de ejemplo (un modelo tipo lineal)

$$\mathbf{w}_j^\top = [w_{j,1}, w_{j,0}]$$

$$salary_i = x_i$$

$$\hat{y}_j = w_{j,1} * x_j + w_{j,0}$$

$$J(\mathbf{w}) = \frac{1}{2m} \sum_{i=1}^m (y_j - w_{j,1} * x_i - w_{j,0})^2$$

# Idea central del GD

- Partimos de  $\mathbf{w}_{(0)}$  (p. ej., aleatorio).
- Iteramos:

$$\mathbf{w}_{(t+1)} = \mathbf{w}_{(t)} - \alpha \nabla_{\mathbf{w}} J(\mathbf{w}_{(t)})$$

- $\alpha =$  **tasa de aprendizaje**: grande  $\rightarrow$  rápido pero inestable; pequeña  $\rightarrow$  estable pero lento.
- Convergencia: buscamos  $\nabla J \approx \mathbf{0}$ .

**Visualización conceptual:** “valle” del error y trayectoria en zig-zag hacia el mínimo.

# Algoritmo de Descenso de Gradiente

**i** Para la estimación de  $w_{j,0}$

$$w_{j+1,0} = w_{j,0} - \alpha \frac{\partial J}{\partial w_{j,0}}$$

$$\frac{\partial J}{\partial w_{j,0}} = \frac{\partial}{\partial w_{j,0}} \left( \frac{1}{2m} \sum_{i=1}^m (y_i - w_{j,1}x_i - w_{j,0})^2 \right)$$

$$\frac{\partial}{\partial w_{j,0}} \left( \frac{1}{2m} \sum_{i=1}^m (y_i - w_{j,1}x_i - w_{j,0})^2 \right) = \frac{1}{m} \sum_{i=1}^m (w_{j,1}x_i + w_{j,0} - y_i)$$

**i** Para la estimación de  $w_{j,1}$

## Variantes: batch, mini-batch, SGD

- **Batch GD:** usa todo el conjunto en cada actualización (costo alto por iteración).
- **Mini-batch GD:** usa lotes pequeños (compromiso eficiencia/ruido).
- **SGD (estocástico):** actualiza con una sola muestra por paso (barato, ruidoso, puede escapar de óptimos pobres).

**Práctica recomendada:** mini-batch (p. ej., 32–256).

# Preprocesamiento y escalado

- **Estandarizar** o **normalizar** las  $x_j$  acelera y estabiliza GD.
- Centrar:  $x_j \leftarrow (x_j - \mu_j)/\sigma_j$ .
- Manejo de outliers y transformaciones (log, Box-Cox) cuando aplique.

# 1.5 EDA

Empezar a usar jupyter.





## Sección 2

### 2. Caso 1 · Regresión lineal múltiple con GD

# Planteamiento

**Objetivo biomédico (ejemplo):** predecir **gasto energético** (kcal) a partir de **edad, IMC y FC**.

Modelo lineal:

$$\hat{y} = \mathbf{w}^\top \mathbf{x} = w_0 + w_1 x_1 + \cdots + w_p x_p$$

Costo (MSE):

$$J(\mathbf{w}) = \frac{1}{2m} \sum_{i=1}^m (y_i - \hat{y}_i)^2$$

Gradiente:

$$\frac{\partial J}{\partial w_j} = -\frac{1}{m} \sum_{i=1}^m (y_i - \hat{y}_i) x_{ij}$$

Actualización:

$$w_j \leftarrow w_j - \alpha \frac{\partial J}{\partial w_j}$$

## Pseudocódigo (mini-batch)

```

in: X (m×p), y (m), , batch_size, epochs
preprocess: X ← standardize(X)

initialize w ← zeros(p+1) # incluye sesgo w0 si se usa X con col

for epoch in 1..epochs:
    for B in iterate_minibatches(X, y, batch_size, shuffle=True):
        Xb, yb ← B
        yhat ← Xb · w
        grad ← (1/|B|) · (Xb · (yhat - yb))
        w ← w - · grad

return w

```

# Diagnóstico y validación

- Curva  $J$  vs. iteraciones (entrenamiento y validación).
- Errores residuales: homocedasticidad, estructura vs. predicción.
- Interpretación clínica de coeficientes  $w_j$  y unidades.
- Comparar con **ecuaciones normales** (solución cerrada) y discutir condicionamiento numérico.



## Sección 3

### 3. Caso 2 · Regresión logística con GD (clasificación 0/1)

# Planteamiento

**Objetivo biomédico (ejemplo):** clasificar **riesgo de enfermedad** (0/1) con panel de biomarcadores.

Modelo:

$$\hat{p} = \sigma(\mathbf{w}^\top \mathbf{x}), \quad \sigma(z) = \frac{1}{1 + e^{-z}}$$

Costo (entropía cruzada):

$$J(\mathbf{w}) = -\frac{1}{m} \sum_{i=1}^m \left[ y_i \log \hat{p}_i + (1 - y_i) \log(1 - \hat{p}_i) \right]$$

Gradiente:

$$\frac{\partial J}{\partial w_j} = \frac{1}{m} \sum_{i=1}^m (\hat{p}_i - y_i) x_{ij}$$

Actualización:

$$\frac{\partial J}{\partial \mathbf{w}}$$



## Pseudocódigo (mini-batch)

```

in:  $X$  ( $m \times p$ ),  $y \in \{0,1\}^m$ , , batch_size, epochs
preprocess:  $X \leftarrow \text{standardize}(X)$ 

initialize  $w \leftarrow \text{zeros}(p+1)$ 

for epoch in 1..epochs:
    for  $B$  in iterate_minibatches( $X$ ,  $y$ , batch_size, shuffle=True):
         $X_b, y_b \leftarrow B$ 
         $z \leftarrow X_b \cdot w$ 
         $p \leftarrow \text{sigmoid}(z)$ 
         $\text{grad} \leftarrow (1/|B|) \cdot (X_b \cdot (p - y_b))$ 
         $w \leftarrow w - \quad \cdot \text{grad}$ 

return  $w$ 

```

# Métricas y curvas

- **AUC-ROC, AUPRC, sensibilidad, especificidad, F1.**
- Elección del **umbral**  $\tau$  por criterio clínico (p. ej., maximizar sensibilidad bajo límite de FPs).
- Calibración: curvas de confiabilidad.

## Visualización de la frontera de decisión

- Con dos características  $(x_1, x_2)$ , la frontera es una **línea** (hiperplano en general).
- Durante GD, la frontera rota/traslada hasta estabilizarse.
- Añadir **términos polinomiales** o **bases** para fronteras no lineales; GD sigue aplicando.



## Sección 4

### 4. Buenas prácticas y discusión aplicada

# Hiperparámetros y trucos prácticos

- **Tasa de aprendizaje ( $\alpha$ ):** búsqueda en rejilla o **programación de tasa** (decay).
- **Inicialización:** pequeña aleatoria (cero puede estancar con ciertas variantes).
- **Barajado** por época y **mini-batches** estratificados si la clase es rara.
- **Regularización** (L2/L1) para estabilidad e interpretabilidad:

$$J_{\lambda} = J + \frac{\lambda}{2} \|\mathbf{w}\|_2^2 \quad (\text{Ridge})$$

- **Detección de fuga de datos** y validación por **sujeto** en estudios clínicos.

## Checklist de la sesión (rápido)

- ☐ Estandarizaste variables de entrada.
- ☐ Definiste costo adecuado (MSE vs. CE).
- ☐ Elegiste mini-batch y  $\alpha$  razonables.
- ☐ Verificaste convergencia con curva de  $J$ .
- ☐ Evaluaste con métricas adecuadas al objetivo clínico.
- ☐ Documentaste supuestos y limitaciones.

# Objetivos de aprendizaje

- **Comprender** los fundamentos de la **Regresión Lineal**, **Regresión Logística** y **Perceptrón Multicapa (MLP)**.
- **Aplicar** estos modelos al contexto de **salud fetal** con datos de **cardiotocografía (CTG)**.
- **Evaluar** el desempeño con métricas adecuadas (MSE, AUC/Log-Loss, matriz de confusión, F1).

- 1 Regresión Lineal
- 2 Regresión Logística
- 3 Perceptrón Multicapa
- 4 Cierre y discusión

**Dataset:** fetal\_health.csv (UCI CTG). **Contexto clínico:** interpretación de CTG (*normal*, *sospechoso*, *patológico*).



## Contexto clínico (CTG)

### ! Defición

Prueba médica que monitoriza simultáneamente la frecuencia cardíaca del feto y la actividad contráctil del útero. Se realiza generalmente durante el tercer trimestre del embarazo y el parto, colocando dos transductores externos (uno para la frecuencia cardíaca fetal y otro para las contracciones) sobre el abdomen de la madre



## Contexto clínico (CTG)

| Característica (Variable en CSV) | Cálculo o Descripción                                                                                                                                                                                                                                                                                           |
|----------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Parámetros Basales               |                                                                                                                                                                                                                                                                                                                 |
| baseline value                   | Es la frecuencia cardíaca fetal (FCF) media aproximada en un segmento de 10 minutos, excluyendo aceleraciones, deceleraciones y períodos de variabilidad marcada ( $>25$ lpm). Se redondea a incrementos de 5 latidos por minuto (lpm).[4, 5, 6, 7, 8] El rango normal se considera entre 110 y 160 lpm.[9, 10] |
| fetal_movement                   | Número de movimientos fetales detectados por segundo.[1, 11, 12]                                                                                                                                                                                                                                                |
| uterine_contractions             | Número de contracciones uterinas por segundo. Se considera normal tener 5 o menos contracciones en 10 minutos.[1, 4, 11, 12]                                                                                                                                                                                    |

## Contexto clínico (CTG)

- CTG registra **FCF** y **contracciones uterinas**.
- Clasificación clínica (FIGO): **normal** / **sospechoso** / **patológico**.
- Variabilidad, aceleraciones y desaceleraciones son claves.


# Regresión Lineal

## Idea clave

Aproxima una relación **lineal**  $\hat{y} = \beta_0 + \sum_j \beta_j x_j$  minimizando **MSE**.

## Ejemplo didáctico (CTG)

Usamos una **variable continua** de CTG como respuesta (p. ej., *histogram\_width*) para ilustrar ajuste y residuales.



# Regresión Logística

## Idea clave

Modela  $P(Y = 1 \mid \mathbf{x}) = \sigma(\beta_0 + \mathbf{x}^\top \beta)$  con **sigmoide**  $\sigma(z) = 1/(1 + e^{-z})$ .

# 1. Definición de Regresión Logística

La **Regresión Logística** es un algoritmo de aprendizaje automático supervisado utilizado fundamentalmente para problemas de **clasificación binaria**.

A pesar de su nombre, su objetivo no es predecir un valor continuo, sino modelar la **probabilidad** ( $P$ ) de que una observación pertenezca a una clase específica (usualmente denotada como  $Y = 1$ ).

El modelo toma variables de entrada (features)  $x_1, \dots, x_n$  y estima  $P(Y = 1|\mathbf{x})$ .

## 2. El Mecanismo Central del Modelo

El modelo logístico opera en dos pasos cruciales:

### 2.1. El Componente Lineal (Logit)

Primero, el modelo calcula una suma ponderada de las entradas, exactamente igual que en una regresión lineal. A este resultado ( $z$ ) se le conoce como **logit** o, más formalmente, **log-odds**.

$$z = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_n x_n$$

- $\beta_0$  es el intercepto (sesgo).
- $\beta_{1\dots n}$  son los coeficientes (pesos) que el modelo aprende.
- El rango de salida de  $z$  es el de todos los números reales:  $(-\infty, +\infty)$ .

### 2.2. La Función Sigmoide (Logística)

Dado que una probabilidad debe estar en el rango  $[0, 1]$ ,  $z$  no puede ser el

### 3. La Relación Clave: Probabilidad y Log-Odds

El concepto central que conecta el modelo lineal con la probabilidad es el **log-odds**. Esta transformación es necesaria para mapear un espacio acotado  $[0, 1]$  a un espacio no acotado  $[-\infty, +\infty]$ .

#### 3.1. De Probabilidad a Log-Odds

La transformación se realiza en dos pasos:

- ➊ **Probabilidad ( $P$ )**: La probabilidad del evento.
  - Rango:  $[0, 1]$
- ➋ **Odds (Momios)**: La razón entre la probabilidad de que ocurra ( $P$ ) y la de que no ocurra ( $1 - P$ ).

$$Odds = \frac{P}{1 - P}$$

- Rango:  $[0, +\infty]$
- ➌ **Log-Odds (Logit)**: El logaritmo natural de los *odds*.



## 4. Interpretación de Coeficientes

Debido a esta relación, los coeficientes ( $\beta_i$ ) del modelo tienen una interpretación específica:

- **Coeficiente**  $\beta_i$ : Un incremento de una unidad en la variable  $x_i$  (manteniendo las demás constantes) genera un cambio de  $\beta_i$  en el **log-odds** de la predicción.
- **Odds Ratio (OR)**: Para una interpretación más intuitiva, se utiliza  $e^{\beta_i}$ . Un incremento de una unidad en  $x_i$  **multiplica** los *odds* por un factor de  $e^{\beta_i}$ .

