

# Descenso de Gradiente en Ciencias Biomédicas

## Regresión lineal múltiple, regresión logística y Redes Neuronales

PhD. Pablo Eduardo Caicedo Rodríguez

2026-01-21

# Objetivos de aprendizaje

- **Comprender** los fundamentos de la **Regresión Lineal, Regresión Logística y Perceptrón Multicapa (MLP)**.
- **Aplicar** estos modelos al contexto de **salud fetal** con datos de **cardiotocografía (CTG)**.
- **Evaluuar** el desempeño con métricas adecuadas (MSE, AUC/Log-Loss, matriz de confusión, F1).

- ① Regresión Lineal
- ② Regresión Logística
- ③ Perceptrón Multicapa
- ④ Cierre y discusión

**Dataset:** `fetal_health.csv` (UCI CTG). **Contexto clínico:** interpretación de CTG (*normal, sospechoso, patológico*).

# Contexto clínico (CTG)

## ! Defición

Prueba médica que monitoriza simultáneamente la frecuencia cardíaca del feto y la actividad contráctil del útero. Se realiza generalmente durante el tercer trimestre del embarazo y el parto, colocando dos transductores externos (uno para la frecuencia cardíaca fetal y otro para las contracciones) sobre el abdomen de la madre



# Contexto clínico (CTG)

Característica (Variable en CSV)	Cálculo o Descripción
Parámetros Basales	
baseline value	Es la frecuencia cardíaca fetal (FCF) media aproximada en un segmento de 10 minutos, excluyendo aceleraciones, deceleraciones y períodos de variabilidad marcada ( $>25$ lpm). Se redondea a incrementos de 5 latidos por minuto (lpm).[4, 5, 6, 7, 8] El rango normal se considera entre 110 y 160 lpm.[9, 10]
fetal_movement	Número de movimientos fetales detectados por segundo.[1, 11, 12]
uterine_contractions	Número de contracciones uterinas por segundo. Se considera normal tener 5 o menos contracciones en 10 minutos.[1, 4, 11, 12]

# Contexto clínico (CTG)

- CTG registra **FCF** y **contracciones uterinas**.
- Clasificación clínica (FIGO): **normal / sospechoso / patológico**.
- Variabilidad, aceleraciones y desaceleraciones son claves.

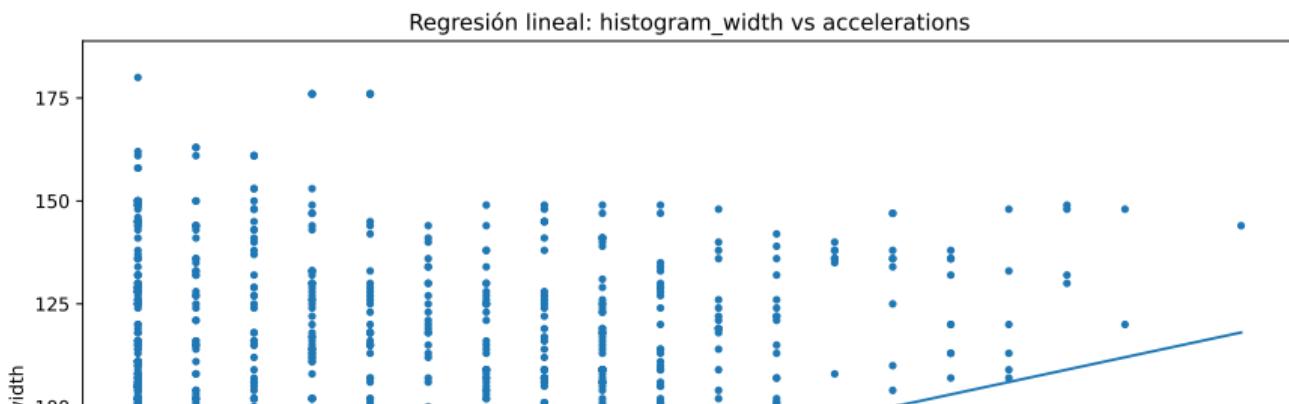
# Regresión Lineal

## Idea clave

Aproxima una relación **lineal**  $\hat{y} = \beta_0 + \sum_j \beta_j x_j$  minimizando **MSE**.

## Ejemplo didáctico (CTG)

Usamos una **variable continua** de CTG como respuesta (p. ej., *histogram\_width*) para ilustrar ajuste y residuales.



# Regresión Logística

## Idea clave

Modela  $P(Y = 1 \mid \mathbf{x}) = \sigma(\beta_0 + \mathbf{x}^\top \boldsymbol{\beta})$  con **sigmoide**  $\sigma(z) = 1/(1 + e^{-z})$ .

# 1. Definición de Regresión Logística

La **Regresión Logística** es un algoritmo de aprendizaje automático supervisado utilizado fundamentalmente para problemas de **clasificación binaria**.

A pesar de su nombre, su objetivo no es predecir un valor continuo, sino modelar la **probabilidad ( $P$ )** de que una observación pertenezca a una clase específica (usualmente denotada como  $Y = 1$ ).

El modelo toma variables de entrada (features)  $x_1, \dots, x_n$  y estima  $P(Y = 1|x)$ .

## 2. El Mecanismo Central del Modelo

El modelo logístico opera en dos pasos cruciales:

### 2.1. El Componente Lineal (Logit)

Primero, el modelo calcula una suma ponderada de las entradas, exactamente igual que en una regresión lineal. A este resultado ( $z$ ) se le conoce como **logit** o, más formalmente, **log-odds**.

$$z = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_n x_n$$

- $\beta_0$  es el intercepto (sesgo).
- $\beta_{1\dots n}$  son los coeficientes (pesos) que el modelo aprende.
- El rango de salida de  $z$  es el de todos los números reales:  $(-\infty, +\infty)$ .

### 2.2. La Función Sísmoide (Logística)

Dado que una probabilidad debe estar en el rango  $[0, 1]$ ,  $z$  no puede ser el

### 3. La Relación Clave: Probabilidad y Log-Odds

El concepto central que conecta el modelo lineal con la probabilidad es el **log-odds**. Esta transformación es necesaria para mapear un espacio acotado  $[0, 1]$  a un espacio no acotado  $[-\infty, +\infty]$ .

#### 3.1. De Probabilidad a Log-Odds

La transformación se realiza en dos pasos:

- ① **Probabilidad ( $P$ )**: La probabilidad del evento.
  - Rango:  $[0, 1]$
- ② **Odds (Momios)**: La razón entre la probabilidad de que ocurra ( $P$ ) y la de que no ocurra ( $1 - P$ ).

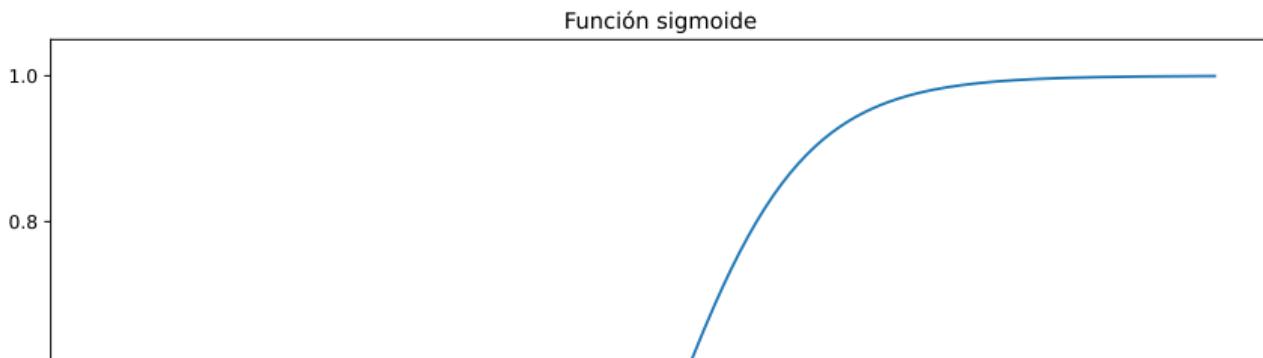
$$Odds = \frac{P}{1 - P}$$

- Rango:  $[0, +\infty]$
- ③ **Log-Odds (Logit)**: El logaritmo natural de los *odds*.

## 4. Interpretación de Coeficientes

Debido a esta relación, los coeficientes ( $\beta_i$ ) del modelo tienen una interpretación específica:

- **Coeficiente  $\beta_i$ :** Un incremento de una unidad en la variable  $x_i$  (manteniendo las demás constantes) genera un cambio de  $\beta_i$  en el **log-odds** de la predicción.
- **Odds Ratio (OR):** Para una interpretación más intuitiva, se utiliza  $e^{\beta_i}$ . Un incremento de una unidad en  $x_i$  **multiplica** los *odds* por un factor de  $e^{\beta_i}$ .





## Sección 1

# Redes Neuronales

# 1. El Punto de Partida: Regresión Lineal

El problema de regresión estándar busca encontrar una función  $f$  que mapee entradas  $\mathbf{x}$  a una salida  $y$ .

En la **Regresión Lineal**, asumimos que la relación es *lineal*:


$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_n x_n + \epsilon$$

O en forma vectorial:

$$y = {}^T \mathbf{x} + \beta_0$$

- **Objetivo:** Encontrar los parámetros óptimos  $(\beta_0)$  que minimizan una función de pérdida (ej. Error Cuadrático Medio, MSE).
- **Limitación:** El modelo está restringido a representar únicamente relaciones lineales.

# 1. El Punto de Partida: Regresión Lineal



## 2. Primera Generalización: El GLM

¿Qué pasa si la salida no es lineal o no sigue una distribución normal? (Ej. clasificación binaria).

Usamos un **Modelo Lineal Generalizado (GLM)**, como la **Regresión Logística**:

- ① **Predictor Lineal ( $z$ )**: Mantenemos el núcleo lineal.

$$z = {}^T \mathbf{x} + \beta_0$$


El resultado  $z$  (el *logit*) puede ir de  $(-\infty, +\infty)$ .

- ② **Función de Enlace (Inversa)**: Aplicamos una transformación no-lineal  $g^{-1}$  para mapear  $z$  al rango deseado (ej.  $[0, 1]$  para probabilidad).

$$\hat{y} = g^{-1}(z) = \sigma(z) = \frac{1}{1 + e^{-z}}$$

- **Avance:** Hemos *generalizado* la regresión. El modelo sigue siendo lineal en

## 2. Primera Generalización: El GLM



### 3. La Neurona: Una Unidad de Regresión

Una **neurona artificial** (o Perceptrón) es conceptualmente idéntica a un modelo de regresión logística (un GLM).

- ① **Agregación Lineal:** Calcula el predictor lineal  $z$  (la entrada neta).

$$z = \sum_{i=1}^n w_i x_i + b$$

- $g(z)$  puede ser  $\text{sigmoid}(z)$ ,  $\tanh(z)$ ,  $\text{ReLU}(z)$ , etc.
- **Concepto Clave:** Una sola neurona es una unidad de regresión (lineal o generalizada) que aprende un *único* límite de decisión (o una respuesta lineal).

### 3. La Neurona: Una Unidad de Regresión

Una **neurona artificial** (o Perceptrón) es conceptualmente idéntica a un modelo de regresión logística (un GLM).

- ➊ **Agregación Lineal:** Calcula el predictor lineal  $z$  (la entrada neta).

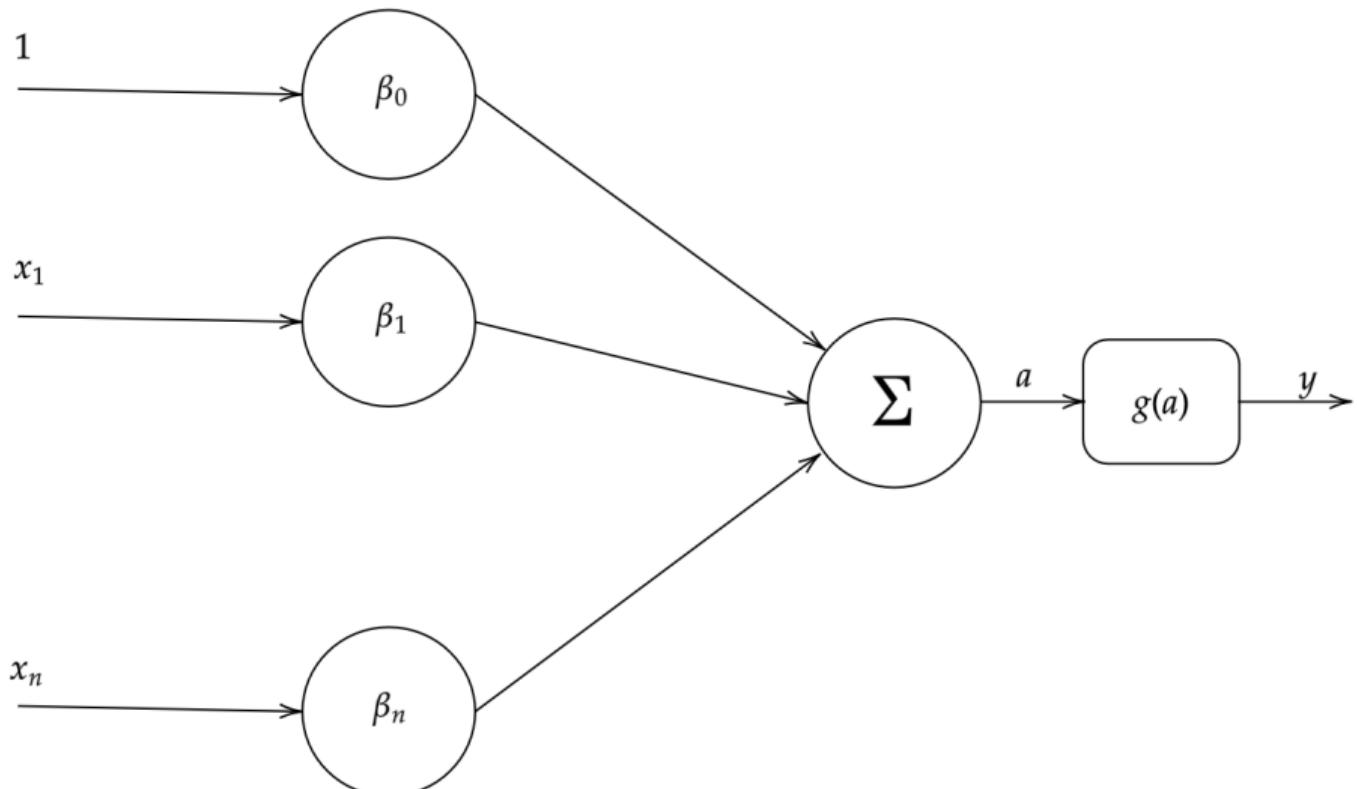
$$z = \sum_{i=1}^n w_i x_i + b$$

- ➋ **Función de Activación:** Aplica una transformación no-lineal  $a$  (la salida).

$$a = g(z)$$

- $g(z)$  puede ser  $\text{sigmoid}(z)$ ,  $\tanh(z)$ ,  $\text{ReLU}(z)$ , etc.
- **Concepto Clave:** Una sola neurona es una unidad de regresión (lineal o generalizada) que aprende un *único* límite de decisión (o una respuesta lineal).

### 3. La Neurona: Una Unidad de Regresión



## 4. La Red: Composición de Funciones

¿Cómo modelar relaciones *altamente* complejas que una sola neurona no puede capturar?

**Respuesta:** Apilando las neuronas en capas.

La salida de una capa de “unidades de regresión” se convierte en la *entrada* de la siguiente capa.

$$\text{Capa 1 (Oculta): } \mathbf{a}^{(1)} = g_1(\mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(1)})$$

$$\text{Capa 2 (Salida): } \hat{y} = g_2(\mathbf{W}^{(2)}\mathbf{a}^{(1)} + \mathbf{b}^{(2)})$$

Esto es una **composición de funciones** anidada:

$$\hat{y} = g_2 \left( \mathbf{W}^{(2)} \left( g_1(\mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(1)}) \right) + \mathbf{b}^{(2)} \right)$$

## 5. El Teorema de Aproximación Universal

Esta arquitectura de “regresiones apiladas” tiene una propiedad fundamental:

**Teorema de Aproximación Universal:** *Una red neuronal feedforward con una sola capa oculta (con una función de activación no lineal, como ReLU o Sigmoide) puede aproximar cualquier función continua  $f(x)$  a un grado arbitrario de precisión, dado un número suficiente de neuronas.*

- Una regresión lineal solo puede encontrar la *mejor línea*.
- Una red neuronal puede encontrar (aprender) la *función  $f(x)$*  en sí misma, sin importar su forma.

**La red neuronal es un regresor generalizado en el sentido más amplio.**

# 6. Generalización del Aprendizaje (Optimización)

El proceso de “entrenamiento” también es una generalización de la regresión.

## Regresión (Lineal/Logística)

- **Pérdida:** Se define una función de coste (Loss Function)  $L(y, \hat{y})$ .
  - Ej. MSE:  $L = (y - \hat{y})^2$
  - Ej. Cross-Entropy:  

$$L = -[y \log(\hat{y}) + (1 - y) \log(1 - \hat{y})]$$
- **Optimización:** Se encuentran los  $w$  y  $b$  que minimizan  $L$  (a menudo usando Descenso de Gradiente).

## Red Neuronal

- **Pérdida:** Se define la *misma* función de coste  $L(y, \hat{y})$  en la salida final.
- **Optimización:** Se encuentran *todos* los  $\mathbf{W}^{(l)}$  y  $\mathbf{b}^{(l)}$  de *todas* las capas que minimizan  $L$ .
- **Mecanismo: Descenso de Gradiente + Backpropagation**  
 (Retropropagación).
  - Backpropagation es simplemente la aplicación sistemática de la **regla de la**

# 7. Conclusión: La Red como $f_\theta(\mathbf{x})$

## 1 Regresión Lineal:

- Modelo:  $f(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b$
- Asume una forma funcional *fija* (lineal).

## 2 GLM (Logística):

- Modelo:  $f(\mathbf{x}) = g(\mathbf{w}^T \mathbf{x} + b)$
- Asume una forma fija (lineal) transformada por una activación fija (ej. sigmoide).


## 3 Red Neuronal (MLP):

- Modelo:  $f(\mathbf{x}) = f_L(\dots f_2(f_1(\mathbf{x})) \dots)$
- **No asume una forma funcional fija.**
- Es un **aproximador de funciones universal** cuyos parámetros  $\theta$  (todos los  $W$  y  $b$ ) se *aprenden* para que  $f_\theta(\mathbf{x})$  imite la verdadera función subyacente  $f(\mathbf{x})$  en los datos.

La red neuronal es la generalización última de la regresión: un sistema que **aprende la forma de la función** desde los datos.

# Perceptrón Multicapa — MLP

**Arquitectura propuesta:**  $21 \rightarrow 32 \rightarrow 16 \rightarrow 3$  con *ReLU* y **softmax** para 3 clases (1, 2, 3).



# Cierre y recomendaciones

- La **interpretación clínica** sigue siendo esencial; el ML complementa, no reemplaza, el juicio médico.
- Validar externamente (dominios LMIC vs HIC), sesgos de muestreo y *data shift*.
- Reportar métricas por clase, especialmente la **clase sospechosa**.

## Referencias (DOI / ISBN)

- Ayres-de-Campos D, et al. **FIGO consensus guidelines on intrapartum fetal monitoring: Cardiotocography.** *Int J Gynaecol Obstet* 2015;131(1):13–24. DOI: 10.1016/j.ijgo.2015.06.020
- Macones GA, et al. **The 2008 NICHD workshop report on electronic fetal monitoring.** *J Obstet Gynecol Neonatal Nurs* 2008. (see *Obstet Gynecol* 2008;112:661–6)
- Hoodbhoy Z, et al. **Use of Machine Learning Algorithms for Prediction of Fetal Risk using Cardiotocographic Data.** *Int J Appl Basic Med Res* 2019;9:226–230. DOI: 10.4103/ijabmr.IJABMR\_370\_18
- James G, Witten D, Hastie T, Tibshirani R. **An Introduction to Statistical Learning (2nd ed.).** Springer, 2021. DOI: 10.1007/978-1-0716-1418-1
- Hosmer DW, Lemeshow S, Sturdivant RX. **Applied Logistic Regression (3rd ed.).** Wiley, 2013. DOI: 10.1002/9781118548387
- Rumelhart DE, Hinton GE, Williams RJ. **Learning representations by** ↗ ↘ ↙ ↛

## Apéndice · Carga de datos y EDA mínimo

fetal\_health

1.0 1655

2.0 295

3.0 176

Name: count, dtype: int64

	count	...
baseline value	2126.0	...
accelerations	2126.0	...
fetal_movement	2126.0	...
uterine_contractions	2126.0	...
light_decelerations	2126.0	...
severe_decelerations	2126.0	...
prolongued_decelerations	2126.0	...
abnormal_short_term_variability	2126.0	...