

Inteligencia Artificial, aprendizaje y evaluación del aprendizaje

Reporte académico ampliado a partir de `reporte.md`

CAICAS - Analytics

2026-06-23

Tabla de contenidos

1	Propósito y alcance	2
2	Punto de partida del documento fuente	2
3	Metodología de búsqueda y validación	3
4	Matriz de fuentes académicas digitales con DOI validado	3
5	IA y aprendizaje: de la automatización a la mediación cognitiva	7
6	Evidencia sobre rendimiento aparente y deuda cognitiva	8
7	Agencia estudiantil, metacognición y autorregulación	9
8	Evaluación del aprendizaje en la era de IA	9
8.1	Insuficiencia del producto final	9
8.2	Evaluación auténtica y vulnerabilidad a la IA	10
9	Limitaciones de la detección automática	10
10	Rediseño de la evaluación: de la prohibición al contrato pedagógico	11
11	Índice de resiliencia evaluativa frente a IA	12
12	Taxonomía post-IA del aprendizaje evaluable	13
13	Propuesta de modelo institucional de evaluación resiliente	14
13.1	Fase 1. Auditoría de vulnerabilidad	14

13.2 Fase 2. Definición del nivel de IA permitido	14
13.3 Fase 3. Diseño de evidencia múltiple	14
13.4 Fase 4. Rúbrica orientada al juicio humano	14
13.5 Fase 5. Retroalimentación para aprendizaje, no solo calificación	15
14 Implicaciones para docentes	15
15 Implicaciones para estudiantes	15
16 Recomendaciones operativas	16
17 Conclusiones	16
18 Referencias	17

1. Propósito y alcance

Este reporte complementa y expande el documento fuente `reporte.md`, cuyo eje argumental sostiene que la inteligencia artificial generativa obliga a reconfigurar la evaluación del aprendizaje, desplazar el foco desde el producto final hacia el proceso cognitivo, y formar competencias de juicio crítico, agencia humana, ética y trazabilidad. El presente documento amplía esa tesis con literatura académica digital sobre IA en educación, aprendizaje asistido por IA, retroalimentación, evaluación formativa, integridad académica y rediseño de instrumentos evaluativos.

El criterio de inclusión usado fue restrictivo: se priorizaron fuentes académicas con DOI verificable, pertinencia explícita con aprendizaje o evaluación, y disponibilidad digital mediante página editorial, repositorio institucional, SSRN, Springer, Elsevier, Wiley, Taylor & Francis, MDPI, AJET o revistas universitarias. No se incorporaron documentos institucionales sin DOI dentro de la matriz de referencias, aunque algunos de ellos puedan ser relevantes para política educativa.

2. Punto de partida del documento fuente

El documento base plantea siete ideas principales que se conservan y se desarrollan en este reporte:

1. La IA generativa no debe entenderse solo como una herramienta tecnológica, sino como un factor de reconfiguración curricular, pedagógica y evaluativa.
2. La evaluación tradicional centrada en textos finales, ensayos estáticos o productos aislados pierde validez cuando dichos productos pueden ser generados, refinados o simulados por IA.

3. La evaluación debe desplazarse hacia evidencias de proceso: bitácoras, defensa oral, explicación de decisiones, trazabilidad de fuentes, iteraciones y transferencia contextual.
4. El uso de IA puede producir un “rendimiento aparente”: mejora del desempeño mientras la herramienta está disponible, sin garantía de aprendizaje autónomo posterior.
5. La respuesta institucional no debería reducirse a vigilancia o detección automática, porque esta estrategia es técnicamente limitada y pedagógicamente insuficiente.
6. Las competencias estudiantiles y docentes deben incluir alfabetización crítica en IA, comprensión de sesgos, privacidad, explicabilidad, ética y límites de la automatización.
7. La evaluación resiliente a la IA debe certificar autonomía, juicio disciplinar y capacidad de transferencia, no solo producción textual.

3. Metodología de búsqueda y validación

La búsqueda se orientó por cuatro familias de literatura:

- **IA en educación superior y aprendizaje:** revisiones sistemáticas y metarrevisiones sobre aplicaciones de IA en educación.
- **IA generativa y aprendizaje:** estudios sobre tutoría, agencia estudiantil, retroalimentación, metacognición y riesgos de dependencia.
- **Evaluación del aprendizaje:** literatura fundacional sobre evaluación formativa, retroalimentación y autorregulación.
- **Evaluación en la era de IA generativa:** rediseño de tareas, autenticidad, integridad académica, escalas de uso permitido de IA y limitaciones de detectores.

La validación DOI se realizó verificando que cada identificador tuviera una página digital resoluble mediante el DOI o estuviera confirmado por la página editorial, repositorio institucional o registro académico de la publicación. La tabla siguiente resume la verificación.

4. Matriz de fuentes académicas digitales con DOI validado

Nº	Fuente	Año	Tema principal	DOI validado	Uso en el reporte
1	Black & Wiliam, <i>Assessment and Classroom Learning</i>	1998	Evaluación formativa y aprendizaje	10.1080/0969595980050102	Fundamento de evaluación para el aprendizaje

Nº	Fuente	Año	Tema principal	DOI validado	Uso en el reporte
2	Nicol & Macfarlane-Dick, <i>Formative Assessment and Self-Regulated Learning</i>	2006	Autorregulación y retroalimentación	10.1080/03075070600572090	Base para metacognición y agencia
3	Hattie & Timperley, <i>The Power of Feedback</i>	2007	Retroalimentación y logro	10.3102/00346543073113705	Diseño de feedback humano/IA
4	Shute, <i>Focus on Formative Feedback</i>	2008	Retroalimentación formativa	10.3102/00346543073113705	feedback eficaz
5	Zawacki-Richter et al., <i>Systematic review of research on artificial intelligence applications in higher education</i>	2019	Revisión sistemática de IA en educación superior	10.1186/s41239-019-0171-0	Mapa de aplicaciones: predicción, evaluación, tutoría, personalización
6	Crompton & Burke, <i>Artificial intelligence in higher education: the state of the field</i>	2023	Estado del campo AIED en educación superior	10.1186/s41239-023-00392-8	Tendencias recientes y usos dominantes
7	Kasneci et al., <i>ChatGPT for good?</i>	2023	Oportunidades y desafíos de LLM en educación	10.1016/j.lindif.2023.102274	Riesgos y posibilidades pedagógicas de LLM

Nº	Fuente	Año	Tema principal	DOI validado	Uso en el reporte
8	Weber-Wulff et al., <i>Testing of detection tools for AI-generated text</i>	2023	Detectores de texto generado por IA	10.1007/s40979-023-00146-z	Crítica a la vigilancia automática
9	Bahroun et al., <i>Transforming Education</i>	2023	Revisión bibliométrica de IA generativa en educación	10.3390/su151722083	Plan de expansión de GenAI educativa
10	Darvishi et al., <i>Impact of AI assistance on student agency</i>	2024	Agencia estudiantil y asistencia de IA	10.1016/j.compe-du.2023.104967	Dependencia, autorregulación y feedback asistido
11	Lee et al., <i>The impact of generative AI on higher education learning and teaching</i>	2024	Perspectivas docentes sobre GenAI	10.1016/j.caeai.2024.100221	Autodignidad institucional y rediseño docente
12	Bond et al., <i>A meta systematic review of artificial intelligence in higher education</i>	2024	Metarrevisión de IA en educación superior	10.1186/s41239-023-00436-z	Necesidad de ética, rigor y colaboración interdisciplinar

Nº	Fuente	Año	Tema principal	DOI validado	Uso en el reporte
13	Zhang et al., <i>A Systematic Literature Review of Empirical Research on Applying Generative AI in Education</i>	2024	Evidencia empírica sobre GenAI en educación	10.1007/s44366-024-0028-5	Aprendizaje, feedback, metacognición y evaluación transformadora
14	Bastani et al., <i>Generative AI Can Harm Learning</i>	2024	Experimento de campo sobre IA y aprendizaje matemático	10.2139/ssrn.4895486	Evidencia sobre rendimiento aparente y dependencia
15	Perkins et al., <i>The Artificial Intelligence Assessment Scale</i>	2024	Marco de integración ética de IA en evaluación	10.53761/q3az-de36	Niveles de uso permitido de IA en evaluación
16	Furze et al., <i>The AI Assessment Scale in action</i>	2024	Implementación piloto de AIAS	10.14742/ajet.94311	Evidencia institucional de rediseño evaluativo
17	Lye & Lim, <i>Generative Artificial Intelligence in Tertiary Education</i>	2024	Principios de rediseño evaluativo	10.3390/educi14060569	Principios “against, avoid, adopt” y evaluación terciaria

Nº	Fuente	Año	Tema principal	DOI validado	Uso en el reporte
18	Zhao, Chapman & Sabet, <i>Generative AI and Educational Assessments</i>	2024	Revisión sistemática de IA generativa y evaluación	10.70953/ERP-Synthesis-2024-12-2006	Síntesis empírica sobre evaluación con GenAI
19	Kofinas, Tsay & Pike, <i>The impact of generative AI on academic integrity of authentic assessments</i>	2025	Integridad académica y evaluación auténtica	10.1111/bjet.13785	Tensión entre autenticidad, integridad y rediseño

5. IA y aprendizaje: de la automatización a la mediación cognitiva

La literatura reciente confirma que la IA en educación no es un fenómeno homogéneo. Zawacki-Richter et al. (2019) organizan sus aplicaciones en cuatro grandes áreas: perfilamiento y predicción, evaluación, sistemas adaptativos/personalización y tutoría inteligente. Esta clasificación es útil porque evita reducir la IA educativa a chatbots o generación de texto. La IA ya interviene en la analítica del aprendizaje, la recomendación de recursos, la retroalimentación automatizada, la detección de patrones de riesgo y la personalización de trayectorias.

Crompton y Burke (2023) muestran que la investigación sobre IA en educación superior se intensificó antes de ChatGPT, pero la irrupción de los modelos generativos aceleró las preguntas pedagógicas. En su revisión, los usos principales de IA se agrupan en evaluación, predicción, asistentes de IA, tutoría inteligente y gestión del aprendizaje. Esta taxonomía permite comprender que el problema no consiste únicamente en impedir el fraude, sino en rediseñar las condiciones bajo las cuales se aprende, se practica, se recibe feedback y se demuestra competencia.

Desde la perspectiva del aprendizaje, la IA puede operar en tres niveles:

1. **Nivel instrumental:** apoya búsqueda, resumen, traducción, organización y generación preliminar de ideas.

2. **Nivel cognitivo:** ofrece andamiaje, pistas, ejemplos, preguntas socráticas, retroalimentación adaptativa y simulaciones.
3. **Nivel epistémico:** modifica qué se considera saber, argumentar, demostrar, programar, diseñar, resolver o crear en un dominio profesional.

El riesgo aparece cuando el nivel instrumental reemplaza al nivel cognitivo. En ese caso, el estudiante produce más rápido, pero piensa menos; entrega un producto plausible, pero no consolida esquemas internos de comprensión. Por tanto, el criterio institucional no debe ser únicamente “usar o no usar IA”, sino determinar si la IA opera como **andamio temporal para aprender** o como **sustituto estable del razonamiento**.

6. Evidencia sobre rendimiento aparente y deuda cognitiva

El concepto de “rendimiento aparente” planteado en el documento fuente encuentra respaldo empírico en Bastani et al. (2024). En un experimento de campo con cerca de mil estudiantes de secundaria en clases de matemáticas, el acceso a GPT-4 mejoró el desempeño durante la práctica asistida. Sin embargo, cuando la herramienta fue retirada, los estudiantes que usaron una versión no guiada del sistema obtuvieron peores resultados que quienes nunca tuvieron acceso a la IA. La interpretación educativa es directa: la IA puede mejorar la ejecución inmediata sin producir aprendizaje transferible.

Este resultado no justifica prohibiciones generales. El mismo estudio muestra que una versión con salvaguardas pedagógicas redujo los efectos negativos. La diferencia no radica solo en el modelo, sino en el **diseño de la interacción**. Una IA que entrega respuestas finales puede deteriorar el aprendizaje; una IA que ofrece pistas, exige explicación, pregunta por el procedimiento y retrasa la solución puede funcionar como tutor.

En términos pedagógicos, la deuda cognitiva aparece cuando:

- el estudiante delega la descomposición del problema;
- no formula hipótesis propias antes de consultar la IA;
- copia soluciones sin reconstruirlas;
- no identifica errores o supuestos del modelo;
- no puede resolver una tarea análoga sin asistencia;
- confunde fluidez textual con comprensión disciplinar.

De aquí se deriva una regla de diseño: **todo uso de IA en actividades de aprendizaje debe incluir un momento sin IA para comprobar transferencia, autonomía y retención conceptual**.

7. Agencia estudiantil, metacognición y autorregulación

La agencia estudiantil es una dimensión crítica. Darvishi et al. (2024) examinan si los estudiantes aprenden de la retroalimentación personalizada generada por IA o si dependen de ella. Esta pregunta es central porque la retroalimentación automatizada puede mejorar la revisión de tareas, pero también desplazar procesos de autoevaluación si el estudiante no participa activamente en la interpretación del feedback.

La literatura clásica sobre evaluación formativa ya había establecido que la retroalimentación eficaz no consiste en entregar correcciones, sino en reducir la brecha entre desempeño actual y desempeño esperado. Black y Wiliam (1998) muestran que la evaluación formativa puede generar ganancias sustanciales de aprendizaje cuando se integra al proceso de enseñanza. Nicol y Macfarlane-Dick (2006) agregan que el feedback debe apoyar la autorregulación: clarificar metas, facilitar autoevaluación, ofrecer información de calidad, fomentar diálogo, motivar, cerrar brechas y proporcionar información útil al docente.

En ambientes con IA, estos principios adquieren mayor relevancia. La retroalimentación generada por IA debe evaluarse mediante cuatro criterios:

Criterio	Pregunta orientadora	Riesgo si se omite
Exactitud disciplinar	¿El feedback es técnicamente correcto?	Aprendizaje de errores plausibles
Acción pedagógica	¿Indica cómo mejorar, no solo qué está mal?	Corrección superficial
Metacognición	¿Obliga al estudiante a explicar su decisión?	Dependencia pasiva
Transferencia	¿Prepara para resolver tareas nuevas?	Rendimiento localizado sin aprendizaje

La IA debe ser configurada como mediadora de autorregulación, no como juez final ni como productor invisible de la respuesta.

8. Evaluación del aprendizaje en la era de IA

8.1. Insuficiencia del producto final

El documento fuente afirma que el ensayo estático o el producto final aislado pierden fuerza evaluativa. Esta afirmación es consistente con la literatura reciente sobre IA generativa y evaluación. Cuando una tarea se puede resolver con una instrucción genérica a un modelo, la evidencia de aprendizaje se vuelve débil. No porque el estudiante necesariamente haya actuado

con deshonestidad, sino porque el instrumento ya no distingue entre desempeño humano, asistencia legítima, delegación parcial o automatización total.

Por tanto, la evaluación debe pasar de una lógica de **verificación de autoría** a una lógica de **validación de competencia**. La pregunta deja de ser “¿quién escribió este texto?” y pasa a ser:

- ¿Puede el estudiante explicar sus decisiones?
- ¿Puede justificar la elección de fuentes, datos, métodos o criterios?
- ¿Puede detectar errores generados por IA?
- ¿Puede transferir el procedimiento a un problema nuevo?
- ¿Puede actuar competentemente en vivo, bajo restricciones realistas?

8.2. Evaluación auténtica y vulnerabilidad a la IA

La evaluación auténtica no queda automáticamente protegida frente a la IA. Kofinas, Tsay y Pike (2025) muestran que la IA generativa también afecta evaluaciones que tradicionalmente se consideraban más resistentes, porque puede ayudar a producir análisis, planes, informes, simulaciones textuales y productos multimodales. La autenticidad, por sí sola, no basta; debe combinarse con trazabilidad, defensa, especificidad contextual y evidencia de proceso.

Una evaluación auténtica resiliente requiere al menos cinco condiciones:

1. **Contexto local o situado:** uso de datos, casos, restricciones o experiencias que no puedan ser resueltas por respuestas genéricas.
2. **Proceso visible:** registro de decisiones, descartes, versiones, prompts, fuentes y cambios.
3. **Juicio disciplinar:** identificación de errores, sesgos, supuestos y límites de la IA.
4. **Interacción evaluativa:** defensa oral, entrevista, demostración en vivo o revisión crítica.
5. **Transferencia:** tarea análoga, variación del caso o aplicación sin IA.

9. Limitaciones de la detección automática

La respuesta institucional centrada en detectores de texto generado por IA es técnicamente débil. Weber-Wulff et al. (2023) evaluaron herramientas de detección y concluyeron que no son suficientemente fiables para tomar decisiones punitivas de alto impacto. Además, la paráfrasis, la traducción automática y la edición humana pueden alterar significativamente el resultado de los detectores.

Esto implica que los detectores no deben ser usados como prueba única de fraude académico. Su uso, si existe, debe limitarse a señal preliminar de revisión pedagógica o administrativa, nunca como evidencia concluyente. Una política institucional responsable debería privilegiar:

- declaración transparente del uso de IA;

- rediseño de tareas;
- entrevistas de validación;
- comparación con evidencia longitudinal del estudiante;
- rúbricas que evalúen proceso, fuentes y juicio;
- procedimientos de debido proceso cuando exista sospecha.

10. Rediseño de la evaluación: de la prohibición al contrato pedagógico

La literatura reciente converge en una conclusión: prohibir genéricamente la IA es poco sostenible. Perkins et al. (2024) proponen la AI Assessment Scale como un marco para definir niveles de uso permitido de IA según los resultados de aprendizaje esperados. Furze et al. (2024) reportan una implementación piloto en la que una escala explícita ayudó a reducir incertidumbre, orientar prácticas docentes y promover mayor transparencia.

La utilidad de este enfoque es que convierte el uso de IA en un **contrato pedagógico**. Cada actividad debe aclarar:

- qué usos de IA están permitidos;
- qué usos deben declararse;
- qué partes deben ser realizadas sin IA;
- qué evidencia de proceso debe entregarse;
- cómo se evaluará la contribución humana;
- qué consecuencias tiene la delegación no declarada.

Una escala institucional mínima podría adoptar cinco niveles:

	Nivel	Condición de uso de IA	Evidencia exigida	Tipo de tarea apropiada
	0	Sin IA	Producción en vivo o bajo supervisión	Exámenes de base, pruebas diagnósticas, habilidades críticas mínimas
	1	IA para exploración	Registro breve de consulta	Lluvia de ideas, búsqueda inicial, delimitación temática
	2	IA para retroalimentación	Versión inicial, feedback recibido y mejora justificada	Ensayos, informes, código, diseño de propuestas

		Condición de uso de IA	Evidencia exigida	Tipo de tarea apropiada
	3	IA como copiloto	Bitácora completa, prompts, decisiones y defensa	Proyectos aplicados, análisis de datos, simulaciones
	4	IA como componente explícito del producto	Auditoría de modelo, validación humana y reflexión crítica	Prototipos, agentes, herramientas educativas, productos profesionales

Esta escala no debe aplicarse de forma uniforme. Debe alinearse con el resultado de aprendizaje. Si el resultado es escritura académica autónoma, el nivel permitido será bajo. Si el resultado es diseñar un flujo de trabajo profesional asistido por IA, el nivel permitido será alto, pero la evaluación deberá centrarse en auditoría, juicio y validación.

11. Índice de resiliencia evaluativa frente a IA

Para operacionalizar el rediseño, se propone un índice simple de resiliencia evaluativa frente a IA. No pretende ser una métrica psicométrica definitiva, sino una herramienta diagnóstica para revisar instrumentos.

$$IRE_{IA} = \frac{P + D + T + M + C}{A + 1}$$

Donde:

- (P): evidencia de proceso, en escala 0–3.
- (D): defensa oral, entrevista o demostración en vivo, en escala 0–3.
- (T): transferencia a una situación nueva, en escala 0–3.
- (M): exigencia metacognitiva o reflexión sobre decisiones, en escala 0–3.
- (C): contextualización local, situada o basada en datos propios, en escala 0–3.
- (A): facilidad de automatización por IA, en escala 0–3.

Interpretación sugerida:

Valor de (IRE_{IA})	Lectura	Acción recomendada
0–2	Alta vulnerabilidad	Rediseñar antes de aplicar
>2–5	Vulnerabilidad media	Añadir trazabilidad, defensa o transferencia

Valor de (IRE_{IA})	Lectura	Acción recomendada
>5-10	Resiliencia aceptable	Aplicar con rúbrica explícita
>10	Alta resiliencia	Usar en evaluación de alto impacto, con control de carga docente

Este índice puede utilizarse en comités curriculares para auditar tareas existentes. Por ejemplo, un ensayo genérico sin defensa puede tener alto (A) y bajo (P, D, T, M, C). En cambio, un portafolio con bitácora, datos locales, defensa oral y tarea de transferencia reduce el riesgo de delegación invisible.

12. Taxonomía post-IA del aprendizaje evaluable

El documento fuente propone desplazar la taxonomía desde verbos de bajo nivel hacia acciones como interpretar, contextualizar, integrar, adaptar, criticar, interrogar, deliberar e innovar. Esta idea puede expandirse en una taxonomía de desempeño evaluable:

Dominio	Pregunta evaluativa	Evidencia robusta
Comprensión	¿El estudiante puede explicar el concepto sin reproducir texto generado?	Explicación oral, mapa conceptual, ejemplo propio
Aplicación	¿Puede usar el concepto en un caso nuevo?	Resolución contextualizada, práctica supervisada
Crítica	¿Puede detectar errores, sesgos o supuestos?	Auditoría de respuesta IA, dictamen técnico
Integración	¿Puede combinar fuentes, datos y métodos?	Portafolio, informe con trazabilidad
Creación	¿Puede producir una solución justificada?	Prototipo, diseño, simulación, producto aplicado
Metacognición	¿Puede explicar cómo aprendió y qué cambió?	Bitácora reflexiva, defensa del proceso
Autonomía	¿Puede desempeñarse sin IA cuando es necesario?	Tarea espejo sin asistencia, entrevista técnica

La clave no es eliminar la IA, sino preservar espacios donde la competencia humana sea observable.

13. Propuesta de modelo institucional de evaluación resiliente

Se propone un modelo en cinco fases.

13.1. Fase 1. Auditoría de vulnerabilidad

Cada instrumento debe ser sometido a una prueba básica: intentar resolverlo con una IA generativa común. Si la IA produce una respuesta de alta calidad con una instrucción genérica, el instrumento es vulnerable. No debe aplicarse sin ajustes.

13.2. Fase 2. Definición del nivel de IA permitido

El docente debe declarar el nivel de IA permitido antes de la actividad. La regla debe estar en la guía, la rúbrica y las instrucciones de entrega. La ambigüedad aumenta el conflicto ético y reduce la validez de la evaluación.

13.3. Fase 3. Diseño de evidencia múltiple

La calificación no debe depender de una sola evidencia textual. Una evaluación resiliente combina:

- producto final;
- bitácora de proceso;
- fuentes verificadas;
- explicación de decisiones;
- revisión de errores;
- defensa oral o entrevista;
- transferencia a caso nuevo.

13.4. Fase 4. Rúbrica orientada al juicio humano

La rúbrica debe separar el valor del producto y el valor del proceso. Un producto correcto con proceso opaco no debe recibir la máxima calificación en actividades de alto impacto. La rúbrica debe incluir criterios como trazabilidad, justificación, crítica de IA, contextualización y autonomía.

13.5. Fase 5. Retroalimentación para aprendizaje, no solo calificación

La evaluación debe cerrar el ciclo formativo. La IA puede apoyar feedback rápido, pero el docente conserva la responsabilidad de validar criterios, ajustar orientaciones y atender errores conceptuales. La retroalimentación debe promover revisión, no simple corrección cosmética.

14. Implicaciones para docentes

El rol docente se desplaza hacia diseño, curaduría, validación y acompañamiento metacognitivo. Las competencias docentes prioritarias son:

- diseñar tareas con distintos niveles de uso permitido de IA;
- formular rúbricas que valoren proceso y transferencia;
- construir defensas orales breves y sostenibles;
- evaluar bitácoras de IA sin convertirlas en carga administrativa excesiva;
- detectar errores plausibles en respuestas generadas;
- enseñar a contrastar fuentes y validar afirmaciones;
- diferenciar entre asistencia legítima y delegación indebida;
- proteger datos personales al usar plataformas externas.

El docente no necesita convertirse en ingeniero de IA, pero sí debe comprender sus efectos sobre el aprendizaje, la autoría, el feedback y la validez evaluativa.

15. Implicaciones para estudiantes

El estudiante debe aprender a usar IA sin perder agencia. Esto exige normas explícitas y entrenamiento progresivo. Las competencias mínimas son:

- declarar el uso de IA con honestidad;
- formular prompts orientados al aprendizaje, no a la sustitución;
- pedir pistas antes que respuestas completas;
- contrastar salidas con fuentes académicas;
- detectar sesgos, errores y alucinaciones;
- explicar qué parte del producto es propia y qué parte fue asistida;
- demostrar transferencia sin IA cuando el resultado de aprendizaje lo requiera.

Una alfabetización crítica en IA no se limita a saber usar herramientas. Incluye saber cuándo no usarlas.

16. Recomendaciones operativas

1. **Crear una política institucional de uso de IA por niveles.** Cada actividad debe indicar explícitamente el nivel permitido de IA.
2. **Eliminar evaluaciones genéricas de bajo contexto.** Preguntas puramente definicionales o ensayos universales son altamente automatizables.
3. **Introducir bitácoras breves de IA.** No deben ser documentos extensos; basta con registrar herramienta, propósito, prompts principales, decisiones y validaciones.
4. **Incluir defensas orales proporcionales.** No toda actividad requiere defensa completa, pero las evaluaciones de alto impacto deberían incluir al menos una entrevista breve o explicación en vivo.
5. **Usar tareas espejo.** Una parte del proceso puede realizarse con IA y otra sin IA, para verificar transferencia.
6. **No usar detectores como evidencia concluyente.** Pueden orientar revisión, pero no reemplazan debido proceso ni juicio docente.
7. **Capacitar en feedback asistido por IA.** El estudiante debe aprender a solicitar retroalimentación útil y a evaluarla críticamente.
8. **Proteger datos personales.** Las guías deben prohibir introducir información sensible de estudiantes, docentes, pacientes, usuarios o instituciones en sistemas externos sin autorización.
9. **Alinear evaluación con resultados de aprendizaje.** La pregunta central es qué competencia humana se certifica y qué tipo de IA es compatible con dicha certificación.
10. **Revisar periódicamente los instrumentos.** La resiliencia evaluativa no es permanente; cambia con la capacidad de los modelos.

17. Conclusiones

La IA generativa no elimina la evaluación, pero sí invalida buena parte de las prácticas evaluativas centradas en productos textuales descontextualizados. El problema no es solo la autoría; es la validez de la inferencia: a partir de una entrega, ¿podemos concluir que el estudiante aprendió? En muchos casos, la respuesta ya no es afirmativa si el instrumento no exige proceso, defensa, transferencia y metacognición.

La literatura revisada permite sostener una posición equilibrada. La IA puede ampliar oportunidades de aprendizaje mediante tutoría, retroalimentación, personalización y apoyo cognitivo. Sin embargo, también puede producir dependencia, rendimiento aparente, pérdida de agencia y debilitamiento de habilidades si se usa como sustituto del esfuerzo intelectual. Por tanto, el desafío central es diseñar interacciones y evaluaciones donde la IA funcione como andamio, no como reemplazo.

La institución educativa debe pasar de la vigilancia reactiva al diseño pedagógico proactivo. Una evaluación resiliente frente a IA no se basa en perseguir estudiantes, sino en construir

evidencias robustas de competencia humana: explicar, justificar, contrastar, transferir, deliberar y actuar con criterio. La autonomía humana no se protege prohibiendo toda tecnología; se protege diseñando condiciones en las que el estudiante deba demostrar que puede pensar con IA, contra la IA y sin IA cuando sea necesario.

18. Referencias

- Black, P., & Wiliam, D. (1998). Assessment and classroom learning. *Assessment in Education: Principles, Policy & Practice*, 5(1), 7–74. <https://doi.org/10.1080/0969595980050102>
- Nicol, D. J., & Macfarlane-Dick, D. (2006). Formative assessment and self-regulated learning: A model and seven principles of good feedback practice. *Studies in Higher Education*, 31(2), 199–218. <https://doi.org/10.1080/03075070600572090>
- Hattie, J., & Timperley, H. (2007). The power of feedback. *Review of Educational Research*, 77(1), 81–112. <https://doi.org/10.3102/003465430298487>
- Shute, V. J. (2008). Focus on formative feedback. *Review of Educational Research*, 78(1), 153–189. <https://doi.org/10.3102/0034654307313795>
- Zawacki-Richter, O., Marín, V. I., Bond, M., & Gouverneur, F. (2019). Systematic review of research on artificial intelligence applications in higher education: Where are the educators? *International Journal of Educational Technology in Higher Education*, 16, Article 39. <https://doi.org/10.1186/s41239-019-0171-0>
- Crompton, H., & Burke, D. (2023). Artificial intelligence in higher education: The state of the field. *International Journal of Educational Technology in Higher Education*, 20, Article 22. <https://doi.org/10.1186/s41239-023-00392-8>
- Kasneci, E., Sessler, K., Küchemann, S., Bannert, M., Dementieva, D., Fischer, F., et al. (2023). ChatGPT for good? On opportunities and challenges of large language models for education. *Learning and Individual Differences*, 103, 102274. <https://doi.org/10.1016/j.lindif.2023.102274>
- Weber-Wulff, D., Anohina-Naumeca, A., Bjelobaba, S., Foltýnek, T., Guerrero-Dib, J., Popoola, O., Šigut, P., & Waddington, L. (2023). Testing of detection tools for AI-generated text. *International Journal for Educational Integrity*, 19, Article 26. <https://doi.org/10.1007/s40979-023-00146-z>
- Bahroun, Z., Anane, C., Ahmed, V., & Zacca, A. (2023). Transforming education: A comprehensive review of generative artificial intelligence in educational settings through bibliometric and content analysis. *Sustainability*, 15(17), 12983. <https://doi.org/10.3390/su151712983>
- Darvishi, A., Khosravi, H., Sadiq, S., Gašević, D., & Siemens, G. (2024). Impact of AI assistance on student agency. *Computers & Education*, 210, 104967. <https://doi.org/10.1016/j.compedu.2023.104967>

- Lee, D., Arnold, M., Srivastava, A., Plastow, K., Strelan, P., Ploeckl, F., Lekkas, D., & Palmer, E. (2024). The impact of generative AI on higher education learning and teaching: A study of educators' perspectives. *Computers and Education: Artificial Intelligence*, 6, 100221. <https://doi.org/10.1016/j.caeai.2024.100221>
- Bond, M., Khosravi, H., De Laat, M., Bergdahl, N., Negrea, V., Oxley, E., Pham, P., Chong, S. W., & Siemens, G. (2024). A meta systematic review of artificial intelligence in higher education: A call for increased ethics, collaboration, and rigour. *International Journal of Educational Technology in Higher Education*, 21, Article 4. <https://doi.org/10.1186/s41239-023-00436-z>
- Zhang, X., Zhang, P., Shen, Y., Liu, M., Wang, Q., Gašević, D., & Fan, Y. (2024). A systematic literature review of empirical research on applying generative artificial intelligence in education. *Frontiers of Digital Education*, 1(3), 223–245. <https://doi.org/10.1007/s44366-024-0028-5>
- Bastani, H., Bastani, O., Sungu, A., Ge, H., Kabakcı, Ö., & Mariman, R. (2024). *Generative AI can harm learning*. The Wharton School Research Paper. <https://doi.org/10.2139/ssrn.4895486>
- Perkins, M., Furze, L., Roe, J., & MacVaugh, J. (2024). The Artificial Intelligence Assessment Scale (AIAS): A framework for ethical integration of generative AI in educational assessment. *Journal of University Teaching and Learning Practice*, 21(06). <https://doi.org/10.53761/q3az-de36>
- Furze, L., Perkins, M., Roe, J., & MacVaugh, J. (2024). The AI Assessment Scale (AIAS) in action: A pilot implementation of GenAI-supported assessment. *Australasian Journal of Educational Technology*, 40(4), 38–55. <https://doi.org/10.14742/ajet.9434>
- Lye, C. Y., & Lim, L. (2024). Generative artificial intelligence in tertiary education: Assessment redesign principles and considerations. *Education Sciences*, 14(6), 569. <https://doi.org/10.3390/educsci14060569>
- Zhao, J., Chapman, E., & Ghassemi Pour Sabet, P. (2024). Generative AI and educational assessments: A systematic review. *Education Research & Perspectives*, 51, 124–155. <https://doi.org/10.70953/ERPv51.2412006>
- Kofinas, A. K., Tsay, C. H.-H., & Pike, D. (2025). The impact of generative AI on academic integrity of authentic assessments within a higher education context. *British Journal of Educational Technology*, 56(6), 2522–2549. <https://doi.org/10.1111/bjet.13585>